

Relatório Técnico Abrangente: Arquitetura Jev, Decodificação Probabilística e a Ascensão dos Modelos "System One"

Introdução: O Paradigma de Decisão Nativa em Máquinas

A evolução das infraestruturas de inteligência artificial (IA) tem sido amplamente dominada por Large Language Models (LLMs) otimizados para a geração fluente de texto e interação humana, um paradigma fundamentado em redes neurais autorregressivas. Contudo, a engenharia de software baseada em IA depara-se com limitações estruturais quando estes modelos são aplicados a fluxos de trabalho que exigem decisões rápidas, determinísticas e tipadas. Em setembro de 2026, a TypeSafe AI — um laboratório fundado por Diogo Almeida (co-inventor do método RLHF na OpenAI), Erik Gafni e Sasha Sheng, com um financiamento inicial de 40 milhões de dólares liderado pela DCVC — lançou comercialmente o modelo "Jev"¹. O modelo introduz e consolida a categoria de modelos "System One". A nomenclatura deriva da teoria dual de processamento cognitivo do psicólogo Daniel Kahneman: enquanto o "System Two" representa o raciocínio lento, deliberativo e sequencial (análogo à geração iterativa de tokens de um LLM), o "System One" materializa a intuição rápida, paralela e estruturada⁵. Adicionalmente, o nome "Jev" é uma referência ao Paradoxo de Jevons (William Stanley Jevons), que postula que o aumento da eficiência na utilização de um recurso paradoxalmente amplifica a sua taxa de consumo⁸. A premissa central é que, ao reduzir drasticamente o custo e a latência das inferências classificatórias, o volume de decisões baseadas em IA incorporadas silenciosamente em blocos lógicos de software ("smart if-statements") explodirá¹⁰.

O presente relatório exaustivo dissectiona a arquitetura subjacente aos modelos System One, a sua calibração probabilística pioneira, o comparativo técnico em relação aos LLMs generativos, o ecossistema nascente de código aberto e as implicações de engenharia para sistemas de automação e orquestração.

1. Arquitetura e Mecânica Interna

A arquitetura de modelos como o Jev representa uma bifurcação deliberada no design de Transformers. O objetivo central é eliminar o gargalo de von Neumann da inteligência artificial generativa: a decodificação sequencial, na qual cada token depende da predição do token anterior⁵.

O Substrato Compartilhado e as Camadas Removidas

Um modelo System One partilha a espinha dorsal de um Large Language Model convencional.

A tokenização baseada em sub-palavras (como Byte-Pair Encoding), as matrizes de *embeddings* vetoriais projetadas num espaço latente de alta dimensionalidade e as sucessivas camadas de *Self-Attention* e *Multilayer Perceptrons* (MLP) são rigorosamente mantidas¹³. Estes componentes garantem que o modelo preserve a capacidade semântica profunda, a compreensão de intenção e o conhecimento de mundo embutido nos pesos durante a fase de pré-treinamento¹⁴.

A divergência estrutural ocorre no cabeçalho do modelo (model head). Em um LLM, o vetor residual da última camada oculta é passado por um *Language Modeling Head* (LM Head) — uma densa camada de projeção linear que mapeia o vetor latente para o vocabulário inteiro (frequentemente de 50.000 a mais de 128.000 tokens), aplicando subsequentemente uma função *softmax* para gerar a distribuição de probabilidade do próximo token¹⁴. No Jev, o LM Head é categoricamente extirpado, bem como o laço (loop) de inferência autorregressiva. Em vez de prever texto, a arquitetura introduz um *Pointer Head* (ou *Decision Head*) desenhado para ler probabilidades diretamente dos estados ocultos pré-calculados em uma única passagem frontal (*single forward pass*)¹⁴.

Máscara de Atenção Causal em Blocos (Block-Causal Attention) e Amostragem Paralela

A genialidade de desempenho da arquitetura reside na manipulação vetorial da máscara de atenção. Uma chamada típica ao Jev envolve um "Estado" (o contexto principal em texto ou JSON) e múltiplas "Questões", cada uma acompanhada de opções tipadas.

Modelos de código aberto que replicaram a arquitetura (como o Kev) revelaram a mecânica probabilística: o Estado e todas as Questões são concatenados numa única sequência de tokens. Contudo, uma máscara de atenção causal em blocos (*block-causal attention mask*) impõe restrições precisas à interação entre esses tokens. O Estado atua como um prefixo compartilhado que todos os tokens subsequentes podem "ver". Em seguida, cada Questão ramifica-se em paralelo, com os seus *Position IDs* sendo reiniciados após o Estado. Um token pertencente à Questão A pode atender a todo o Estado e aos tokens da própria Questão A, mas o seu valor na matriz de atenção em relação à Questão B é forçado a infinito negativo (ou zero lógico)¹⁸.

Esta topologia resolve dois problemas críticos: (a) previne o vazamento de contexto, assegurando que as probabilidades calculadas para uma decisão não contaminem as respostas de outra; (b) permite que o cálculo computacional intensivo dos tensores de *Key* e *Value* (KV Cache) correspondentes ao Estado seja feito uma única vez na fase de *prefill*. O *Pointer Head* opera projetando o estado oculto de cada candidato para uma chave vetorial (por exemplo, de 896 para 256 dimensões) e executa um produto escalar (*scaled dot-product*) contra o vetor de consulta (*query*) gerado pela instrução da pergunta¹⁸. O resultado é normalizado via *softmax* estritamente sobre as opções legais declaradas no momento da chamada, resultando na amostragem simultânea de dezenas de perguntas na mesma janela de milissegundos que um LLM levaria para processar o primeiro token (*Time-to-First-Token*)¹⁸.

Primitivas Estritas de Decisão: Choice, Score e Noul

O mapeamento direto da representação latente manifesta-se no cliente através de três

primitivas de dados inflexíveis, desenhadas para garantir a tipagem rigorosa que dá nome à TypeSafe AI²¹.

1. **Choice (Classificação Categórica):** Permite selecionar uma opção exclusiva a partir de um conjunto de candidatos definidos pelo utilizador (teto estrutural de até 255 opções na arquitetura Jev)²². O programador fornece um dicionário contendo os *labels* e descrições semânticas detalhadas de quando a opção deve ser aplicada. A API devolve o *label* eleito, a distribuição absoluta de probabilidades cobrindo todos os candidatos e um valor independente de "confiança" que quantifica o grau de acuidade (pico) da distribuição²¹.
2. **Score (Escalonamento Ordinal e Regressão Contínua):** Avalia o contexto num espectro ordenado. Ao invés de uma classificação discreta isolada, o engenheiro fornece um vetor (com 2 a 10 níveis descritivos ordenados do menor para o maior). O *Pointer Head* gera uma distribuição, mas o modelo computa e devolve o "valor esperado" dessa distribuição. Se houver incerteza epistemológica entre o nível 1 e o nível 2, a API poderá devolver 1.43 ou 1.78, gerando uma representação contínua do posicionamento latente e fornecendo um limiar de roteamento excepcionalmente preciso²¹.
3. **Noul (Probabilidade Booleana / Bernoulli):** O termo "Noul", cunhado pelo fundador da TypeSafe, é um neologismo derivado da distribuição de Bernoulli²⁴. Trata-se do mapeamento de uma variável booleana, onde a questão declarativa possui apenas duas saídas lógicas (Verdadeiro ou Falso). A primitiva não devolve um campo de "confiança" apartado, visto que a probabilidade matemática flutuante em si mesma (0.00 a 1.00) consubstancia a certeza da proposição. Uma devolução próxima a 0.50 não significa um valor mediano, mas sim ambiguidade informativa (ausência de suporte na evidência textual)²².

Gestão do Contexto (State) e Fadiga de Atenção (Context Rot)

Um modelo "System One" processa informações de modo assíncrono. Em chamadas convencionais, o limite de contexto atua diferentemente de um LLM: permite-se um máximo consolidado de 64.000 (64k) tokens entre a soma do contexto global e todas as ramificações de perguntas, com a imposição estrita de que o Estado mais a pergunta mais longa não exceda 32.000 (32k) tokens individuais²⁷.

Dado que não existe um mecanismo de raciocínio passo-a-passo (*Chain-of-Thought* ou *CoT*), o Jev está sujeito ao que os engenheiros designam como "Fadiga de Atenção" ou *Context Rot*²⁷. Num LLM, o rastro gerativo pré-resposta funciona como um filtro de atenção secundário que isola o ruído ao forçar o modelo a "refletir" localmente no tensor iterativo. Numa arquitetura de passagem única, tensores densamente ruidosos diluem as pontuações do produto escalar no *Pointer Head*. Na presença de dezenas de milhares de logs de execução irrelevantes, a precisão direcional das opções no Jev perde densidade entrópica. Distribuições categóricas sofrem achatamento e valores *Noul* colapsam em direção ao centro lógico (0.50)²⁷. Por conseguinte, a higiene do vetor semântico (Signal-to-Noise Ratio) enviado na *payload* do JSON repousa inteiramente nas mãos do engenheiro de software²⁷.

2. Metodologia de Treinamento e Calibração

Probabilística

A utilidade de um sistema numérico depende primariamente da honestidade dos seus coeficientes. A mera conversão de arquiteturas para predição direta é uma ciência estabelecida (como *classification heads* em redes BERT tradicionais). A inovação singular do ecossistema System One é a alteração profunda do objetivo de função de perda (loss function) pós-treinamento através da disciplina matemática de calibração¹⁵.

RLCD (Reinforcement Learning for Calibrated Decisions) vs. RLHF / DPO

A ascensão dos assistentes virtuais modernos deve-se amplamente ao *Reinforcement Learning from Human Feedback* (RLHF) e técnicas homólogas como o *Direct Preference Optimization* (DPO). Nestes paradigmas, modelos de linguagem latentes são otimizados contra um modelo de recompensa treinado a partir de avaliações humanas¹⁵. O RLHF prioriza o alinhamento estilístico: os avaliadores tendem a classificar respostas assertivas, educadas e estruturadas como melhores do que repostas hesitantes, mesmo que o modelo careça de suporte base. Isto induz sistematicamente anomalias como *sycophancy* (adulação) e superconfiança em cenários falaciosos, prejudicando irremediavelmente as distribuições probabilísticas cruas dos *logits* nesses modelos³⁰.

A TypeSafe AI propôs a substituição metodológica pelo *Reinforcement Learning for Calibrated Decisions* (RLCD)²⁹. Em contraste com a maximização da preferência humana, o RLCD obriga a rede neural a correlacionar rigidamente o seu nível de confiança relatado com a sua precisão empírica global¹⁵. Uma decisão de *Choice* com um valor de confiança de 0.85 deve estar provada empiricamente correta em 85% dos cenários em macroescala³⁰. Se o modelo exibir uma tendência para emitir probabilidades exageradas (ex: prever confiança de 0.99 para uma taxa de sucesso de 70%), os gradientes de penalidade forçam o alisamento logarítmico dos pesos¹⁴.

Dinâmica das Regras Próprias de Pontuação (Brier Score)

O alicerce da calibração num modelo RLCD obedece aos axiomas das Regras de Pontuação Estritamente Próprias (*Strictly Proper Scoring Rules*), as únicas equações que garantem que o valor preditivo ótimo ocorre apenas quando a distribuição informada coincide com o estado de crença real do estimador¹⁴. Durante o refinamento dos *Pointer Heads*, otimizações empregam a penalização conjunta de *Cross-Entropy* e *Brier Score*³³. A formulação matemática do *Brier Score* (BS) quantifica o Erro Quadrático Médio das previsões multinomiais ou booleanas:

$$BS = \frac{1}{N} \sum_{i=1}^N (p_i - o_i)^2$$

Onde p_i é a probabilidade atribuída à classe elegível e o_i é a observação binária real do

ground truth (1 para a classe correta, 0 para as demais). Ao associar este fator quadrático à perda de *Negative Log-Likelihood* (NLL), modelos de sistema um não são recompensados simplesmente por estarem corretos, mas por dimensionarem de forma rigorosa as suas vulnerabilidades de incerteza¹⁴.

Pipelines de Dados Sintéticos e Invariância na Saída (Determinismo)

O RLCD requer conjuntos de validação de massa cujo rótulo principal contenha o valor imutável da realidade (*ground truth*), livre da incerteza inerente aos revisores humanos. Para alcançar isso, engenheiros recorrem a pipelines sintéticos invertidos¹³. Um sistema algorítmico gera uma série de matrizes de regras e propriedades de classes fechadas, e grandes LLMs são instigados a fabricar narrativas ou cenários de casos simulando os artefatos, assegurando assim que as categorias (o gabarito) sejam irrefutáveis.

Um subproduto prático de não existir amostragem heurística de texto na API do Jev é o seu total determinismo funcional, ainda que a sua matriz de decisão se baseie no cálculo estatístico latente estocástico⁵. Em LLMs tradicionais, hiperparâmetros como a temperatura influenciam a amostragem top-p e as roletas viciadas durante a decodificação da cadeia de Markov. Ao utilizar primitivas tipadas sem um ciclo gerativo decodificador, o API fornece diretamente os escalares *softmax* extraídos pós-temperatura parametrizada matematicamente no servidor¹⁶. Submeter o mesmo Estado, com idênticas Questões e definições de Opções, produzirá resultados idênticos até às últimas casas decimais em solicitações consecutivas, solidificando a confiabilidade operacional para as engenharias de regressão e teste de software.

3. Comparativo Técnico: Jev (System One) vs. LLMs Tradicionais

A proliferação de especificações recentes para *Structured Outputs* (ex: "JSON Mode" da OpenAI para o GPT-4o, ou mecanismos do Claude 3.5 Sonnet e Gemini 1.5 Pro) criou um debate sobre a necessidade de modelos decisórios isolados. A resposta reside nas margens inelásticas da decodificação generativa¹⁴.

Quando se obriga um LLM de fronteira a responder a um esquema restrito (Constrained Decoding), métodos de *bitmasking* sobre os *logits* desativam sequências ilegais e gramáticas anormais na estrutura JSON. No entanto, o LLM ainda precisa calcular a rede densa na sua totalidade, projetar a atenção em todos os vetores, e iterar dezenas ou centenas de vezes para emitir não só os dados requeridos, como aspas, chaves, colchetes, indentações e delimitadores de *string*¹⁴. O Tempo Até a Resposta Completa (*Total Time to Interactive* - TTI) num System Two escala proporcionalmente ao tamanho do JSON, acarretando custos monetários tanto de *inputs* quanto de *outputs*. Em contraponto, o Jev resolve o vetor semântico concorrentemente numa única rodada, resultando numa supressão assombrosa de custos computacionais e latência, conforme validado por avaliações independentes.

Tabela Comparativa Detalhada

Recurso / Métrica	LLMs Tradicionais	Jev / System One Models
-------------------	-------------------	-------------------------

	(System Two)	
Paradigma de Inferência	Decodificação Autorregressiva; sequencial (token a token).	Passagem Única Frontal (<i>Single Forward Pass</i>). Amostragem paralela de atenção causal em bloco ¹⁹ .
Latência Média	3.000 ms a 15.000+ ms (Altamente escalável consoante a resposta gerada) ⁷ .	~70 ms a 500 ms (Tempo independente do volume de respostas requeridas) ⁷ .
Custo Computacional e Faturamento	Alto. Bilhetagem sobre tokens de entrada e geração ¹⁰ .	Marginal. ~US\$ 0.042 por 1 milhão de tokens (input). Saída gratuita (output) ¹⁰ .
Integridade Estrutural (<i>Type Safety</i>)	Vulnerável. Depende de <i>parsing</i> e validações externas. Risco de <i>schema hallucinations</i> ¹⁴ .	Garantia matemática. 0% de erros de sintaxe ou respostas fora do escopo pré-definido ⁵ .
Capacidades Epistemológicas e Explicabilidade	Alta. A adoção de cadeias de raciocínio (<i>Chain-of-Thought</i>) expande e cristaliza as deduções lógicas.	Nula. Baseado exclusivamente no mapeamento instintivo (<i>Zero-Shot intuition</i>) sobre as representações semânticas embutidas ²⁸ .
Perfil de Alucinação / Falha	Inventa factos (<i>Hallucination</i>), altera a sintaxe ou omite nós vitais do JSON quando pressionado ²⁸ .	Inventa certezas estatísticas (<i>Alucinação de Julgamento</i>). Atribui altas probabilidades a associações espúrias caso submetido a dados ininterpretáveis ²⁸ .

Desempenho Analítico e Benchmarks Empíricos

Os ensaios publicados em 2026 forneceram a confirmação metrológica do paradigma de decisão estruturada:

- **Acurácia Bruta:** Num rastreio independente conduzido por Ibrahim e Zaki (*arXiv:2609.24574*) cobrindo 18 tarefas de anotação de Ciências Sociais (7.977 itens), o Jev obteve uma exatidão equivalente à de LLMs de classe intermediária³¹. Quando

colocado contra um modelo System 2 otimizado (ex: a série Claude Fable 5.1 ou GPT-6 Astra), o Jev exibiu um déficit persistente, ficando para trás por uma margem mediana de 11.6 pontos na métrica de Macro-F1 na maioria dos testes empíricos limpos²⁸.

- **Eficiência de Custo/Latência:** Contudo, esta desvantagem posicional é suprimida pelo benefício do custo: a mesma análise sublinhou que a arquitetura Jev era em média 44 vezes mais barata em custos apurados que as inferências nos terminais de ponta (fronteira)³¹. Adicionalmente, análises independentes evidenciaram ser de 9 a 12 vezes mais rápido no processamento *end-to-end* face aos LLMs estruturados²⁸. Em aplicações periciais extensas — como no estudo de Rafe & Das (*arXiv:2609.24052*) escalando quase 500 mil registros policiais textuais num modelo macro de 27 rubricas cruzadas —, obteve-se um assinalável limite F1 de 0.908 em dados do mundo real contra alinhadores humanos, onde as opções equivalentes no ecossistema clássico resultariam numa explosão orçamental com ganhos ínfimos na faixa dos ~0.05 de índice de acurácia suplementar³⁹.

4. Mapeamento do Mercado e Alternativas Open

Source

A validação da premissa System One desencadeou paralelismos rápidos e inovações robustas no cenário do *código aberto* (FOSS). Embora o serviço comercial permaneça em formato de API fechada, a engenharia de ML mapeou e consolidou abordagens técnicas capazes de replicar ou simular o modelo matemático sem a emissão serial de tokens.

Encoders e Natural Language Inference (NLI) em Zero-Shot

Para as corporações que operam sob restrições críticas de soberania de dados ou isolamento perimetral, as arquiteturas focadas em codificadores (Encoders puros), adaptadas para tarefas de inferência de pares (NLI), assumem frequentemente funções comparáveis ao Jev. Os modelos de *Cross-Encoder* e frameworks construídos sobre arquiteturas *SetFit* submetem os vetores do documento-alvo concatenados aos rótulos sintáticos em formulações como de similaridade e implicação de premissa-hipótese²⁵.

Técnicas implementadas no ecossistema Hugging Face sobre iterações de *ModernBERT*, *DeBERTa* e *RoBERTa-large-MNLI* processam avaliações categóricas (equivalentes à primitiva *Choice*) ou inferências booleanas (equivalentes à primitiva *Noul*) sob acelerações nativas de hardware *ONNX Runtime*, alcançando tempos médios de latência inferiores a 30 milissegundos num processador convencional, virtualmente suprimindo a dependência de GPUs para inferência categórica não linguística²⁵. Todavia, esses métodos dependem de heurísticas limitadas de pontuação escalar, o que historicamente restringe o nível de calibração fidedigna comparado às técnicas baseadas em *loss* logarítmico calibrado.

Frameworks de Gramática e Decodificação Guiada

Para equipes detentoras de LLMs locais (*Llama*, *Qwen*, *Mistral*), infraestruturas intermédias interceptam as saídas na camada matricial usando FSM (Máquinas de Estados Finitos) baseadas em Regex ou EBNF para suprimir sequências incompatíveis com esquemas arbitrários¹⁴. Ferramentas maduras como *Outlines*, associadas ao despachante universal *vLLM*,

SGLang (utilizando motores como o *XGrammar*) ou diretamente no pacote *llama.cpp* com esquemas nativos (*grammars*), operam na vanguarda da geração sintaticamente válida¹⁴. Embora essas frameworks igualem a integridade tipada do Jev, anulando alucinações gramaticais, elas falham na replicação do seu desempenho de latência estrutural. Como a geração de cada caractere na saída JSON permanece restrita à natureza causal subjacente da rede (cada token deve avançar o cache antes do cálculo do próximo), aplicações em laços rápidos (loops agênticos) mantêm restrições significativas no desempenho sub-segundo¹⁴.

A Ascensão das Réplicas "System One" Locais

Pesquisadores desconstruíram a caixa-preta da API de System One da TypeSafe, resultando na concepção de simulacros e réplicas que fundem o suporte *block-causal* e as abstrações de *pointer head*. O ecossistema aberto consolidou três abordagens paradigmáticas:

1. **Kev (Jared Palmer):** O ecossistema Kev baseou-se nos modelos pré-treinados Qwen / Qwen 2.5 / Qwen 3.5 da Alibaba (escalando desde versões incrustáveis de 0.5B e 0.8B até tensores pesados de 9B parâmetros). Mediante a incorporação de um tensor LoRA (*Low-Rank Adaptation*) somado a um módulo *pointer head* e à restrição da janela contextual por ramificação paralela através de máscara de atenção de blocos causais, o Kev cumpre rigorosamente os contratos da API /v1/systemone exigidos pelos SDKs da TypeSafe¹⁸. Ainda que se sobressaia no controle formatado sem previsões linguísticas, a dependência em treinos sintéticos generalistas impõe severos declínios de precisão na interpretação lógica de classes não abordadas durante a sintonia (out-of-domain degradation), e um subsequente erro de calibração Expected Calibration Error (ECE) mais volátil fora da distribuição original⁴³.
2. **Laya:** Esta formulação foca a generalização paralela com especial otimização temporal. Consolidado nos parâmetros eficientes do *ModernBERT* e *mmBERT* multilingue (cerca de 421M Parâmetros), a ramificação subordina as ativações de saída aos princípios da Proximal Policy Optimization (PPO), desenhando assim uma correlação linear da pontuação probabilística sem depender de LLMs decodificadores maciços²³.
3. **JevLite / Scame.ai:** Proposto na literatura científica por Ren et al. (*arXiv:2609.23959*), o JevLite foi implementado focado na triagem e detecção forense de chamadas telefônicas (Scam Calls). Através do empacotamento restrito das "opções tipadas" processadas num tensor reduzido do Qwen3-4B (sem abstração iterativa final), a equipa atingiu limiares de segurança (AUROC .974) notáveis e avaliações probabilísticas rigorosas com processamento completo na marca invejável de 64.5 milissegundos por chamada inferencial local sem geração de resposta³³.

O gargalo fundamental, todavia, da equiparação de um modelo open source versus a fronteira comercial como o Jev prende-se à calibração. A TypeSafe AI obteve a maestria do dimensionamento do *Brier Score* por possuir acesso financeiro e volumétrico a bilhões de itens de dados RLCD de verificação absoluta; engenheiros independentes não possuem acesso rotineiro a vastos volumes de dados rotulados e depurados de incerteza ontológica necessários à convergência probabilística do método.

5. Aplicações Práticas, Engenharia de Sistemas e

Limitações

A incorporação das respostas de modelos não generativos exige repensar o lugar que a inteligência desempenha na árvore de decisão do microserviço. Sistemas contemporâneos abandonam o modelo como criador isolado, assumindo-o como uma camada utilitária de classificação em massa.

Padrões de Arquitetura e Integração Programática

Ao nível do código, a comunicação com um servidor TypeSafe ou uma das alternativas locais conformes (Kev) evita o clássico engajamento de formatação linguística (prompt engineering) e opta por parâmetros declarativos nativos. O SDK sublinha as três abstrações.

Abaixo ilustra-se um exemplo metodológico conceptual na framework Python do typesafe-sdk, modelando a avaliação do que o autor Diogo Almeida define como *Gatekeeping* num ambiente de atendimento²⁶:

```
Python
from typesafe_sdk import TypeSafeClient, Choice, Score, Now
import os

client = TypeSafeClient(api_key=os.environ.get("TYPESAFE_API_KEY"))

estado_da_sessão = """
[LOG] O utilizador executou falha de login 4 vezes no portal VPN na última hora.
[USER_MSG] 'Por favor, reseta urgentemente a minha senha, perdi o telefone MFA.'
"""

resposta = client.system_one(
    state=estado_da_sessão,
    questions=[
        "tipo_acidente" Choice(
            instructions="Classifica o tipo de requisição de segurança operacional."
            criteria=[
                "acesso_bloqueado" "O utilizador tem um problema de senha ou MFA."
                "falsa_identidade" "Sinais prováveis de intrusão ou requisições sob spoofing."
                "suporte_geral" "Perguntas banais que não requerem intervenção imediata."
            ]
        )
    ],
    "risco_violacao" Score(
        instructions="Qual o nível estimado de risco desta transação na superfície de ataque?"
        criteria=[
            "Normal/Previsível"
        ]
    )
)
```

```

"Alerta Leve - Requer confirmação verbal"
"Intervenção Crítica - Desativar os endpoints imediatos"
[
    "acao_automatizada" Noul
]
instructions: "As políticas da empresa permitem reset automático nestas condições
específicas."
[
    [
        # Acessando respostas tipadas instantaneamente sem casting/JSON decoding
        risco_estimado = resposta.answer["risco_violacao"] score # Retorna, ex: 1.83
        confianca_identificacao = resposta.answer["tipo_acidente"] confidence # Retorna, ex: 0.94
       acao_direta_legal = resposta.answer["acao_automatizada"] noul # Retorna, ex: 0.08
        (Probabilidade muito baixa)
    ]
]

```

No ecossistema avançado de validação sintática do Python, como o Pydantic AI, a integração efetua o encadeamento abstrato através de entidades como a `TypeSafeModel`. O motor da biblioteca intercepta e submete os campos da classe `BaseModel` estrita do Pydantic convertidos de forma implícita em *Choice*, *Noul* ou *Score*, devolvendo os objetos sem intervenção de parsing¹⁶.

Evolução Arquitetural: De RAG a RAD (Retrieval-Augmented Decision)

Talvez a aplicação mais disruptiva do paradigma de decisão paralela e quantitativa resida na substituição dos motores interpretativos de recuperação. Sistemas RAG (Retrieval-Augmented Generation) injetam parágrafos recuperados num LLM de forma a condicionar as suas sentenças de resposta à evidência factual recuperada da *Vector Database*. No entanto, em infraestruturas forenses, análises regulatórias ou aprovações de contratos de crédito, as auditorias organizacionais inviabilizam a adoção de texto não determinístico cuja origem de raciocínio é obscurecida pelo mecanismo algorítmico criativo do modelo⁴⁸.

A emergência do *Retrieval-Augmented Decision (RAD)* inverte o destino da matriz semântica. O banco de conhecimentos é recuperado em formato de embeddings estruturais de maneira similar, contudo a injeção condicional no nó terminal é operada num classificador System One. Os algoritmos (RAD) cruzam um conjunto enorme de diretivas industriais recuperadas perante métricas quantitativas de *MCDM (Multi-Criteria Decision Making)* submetendo as comparações ao modelo, cujo resultado extrai Scores paralelos isolados e exibe um mapeamento relacional determinístico de probabilidade⁴⁸. De acordo com os trabalhos como de Wang et al. (2025) e as investigações na Universidade Técnica submetida nas referências bibliográficas do domínio académico (*arXiv:2505.18483*, *arXiv:2503.13861*), os relatórios estruturados do método RAD ultrapassaram expressivamente a acurácia generativa e fiabilidade dedutiva comparados a todos os métodos RAG convencionais limitados aos seus homólogos narrativos abertos, pois não diluem os axiomas da norma na redação sintética da

inferência criativa⁵⁰.

Dinâmicas de Calibração Adicionais: Platt Scaling e Regressão

Isotônica

Dada a inibição intencional e comercial da disponibilização dos pesos centrais para realização de sessões iterativas profundas de re-sintonia (Fine-tuning) por clientes e estúdios corporativos, o enfrentamento aos desvios estatísticos perimetrais da IA requer medidas operativas extrínsecas. O decaimento contínuo do índice de ECE (*Expected Calibration Error*) por deslocamento de distribuição (*Distribution Shift* - quando a IA enfrenta nomenclaturas textuais ausentes do seu cômputo semântico primitivo) demanda retificações no software de retaguarda.

A mitigação técnica padrão efetua-se mediante mapeamento probabilístico logístico pós-inferência, notadamente pelo uso do algoritmo *Platt Scaling* e/ou modelos de *Regressão Isotônica*³⁴. O *Platt Scaling* aplica uma sub-regressão paramétrica que adequa e curva a saída original pseudo-probabilística não confiável da interface às coordenadas perfeitamente reais das proporções e limites absolutos, mitigando a inflação desmedida da confiança do nó decisório. Ao monitorizar dados empíricos de forma assíncrona, e computar *Platt Scales*, os engenheiros garantem a integridade decisória do orquestrador do microserviço mesmo com uma IA cujo escopo primário original estivesse desviado ou estagnado analiticamente, superando as perdas logarítmicas de calibração inerentes na extração em cauda longa¹⁴.

Conforme relatado nos estudos como os de Rafe e Das no tratamento do vasto corpus processual estadual (Texas), intervenções via Escalonamento (Scaling) e refit ex-ante cortaram os índices ECE pelo fator absurdo de até 3,35x a margem basal descalibrada reportada, consolidando as prerrogativas industriais de automação segura de decisões em massa sem os LLMs multibilionários periciais²⁸.

Limitações Estruturais e Alucinações Probabilísticas (Hallucination of Judgment)

Nenhum modelo fundacional substitui na plenitude todas as modalidades da cognição baseada em IA. Os paradigmas desenhados sob amostragem num passe singular de decisão padecem de vulnerabilidades intrínsecas:

1. **Limitação Dimensional das Primitivas:** Como a máscara restritiva atua sobre listas exclusivas, os dicionários de escolha submetidos como descritores para as classes de *Choice* limitam-se fisicamente no máximo computável de arquitetura. Atualmente o teto alocado gira em torno de 255 ramificações de alternativas tipificadas e, por sua vez, a classe escalar e linear do *Score* tolera 10 rubricas ordinais interpostas²². Adicionalmente, por se restringirem a embeddings logísticos, não há processamento intermodal primário na interface comercial; áudios, imagens e instâncias não-textuais demandam OCR e processamento acústico precedente no funil perimetral¹⁰.
2. **Suscetibilidade Morfológica Direcional (Order and Phrasing Sensitivity):** Sendo ausente o elo raciocinante gradativo, a IA expõe o seu estômago epistemológico através da labilidade linguística das descrições. As avaliações abertas mostraram que a troca estrita nas ordens sintáticas e reordenação lexicográfica na opção candidata

impactaram em colapsos dramáticos do AUROC e provocaram anulações invertidas do p90 em centenas de execuções probabilísticas isoladas, penalizando as saídas na matriz²⁸. A descrição inadequada dos vetores nos limites fronteiros (ex: instruir um limiar sem delimitação lógica absoluta) gera a captura desmedida de atenção espúria.

3. **Alucinação de Julgamento / Colapso Dissonante:** Desprovidos da flexibilidade semântica de "abstenção informada", modelos como Jev demonstram o viés da obrigação resolutive. Ao se injetarem problemas insolúveis e eventos imensuráveis de cunho inteiramente heurístico na base analítica (por exemplo, pedir para que classifiquem confiantemente a probabilidade do lançamento matemático num dado simulado onde todas opções possuíam 17%), testes metrológicos verificaram instâncias onde as arquiteturas atribuíram estupendos escores ilusórios e fraudulentos de 83% de confiabilidade aparente à saída²⁸. Quando instigados sob falácias e questões epistemologicamente viciadas em contextos ambíguos, os *System One models* sofrem colapso para as inclinações dos vetores do contexto espúrio da instrução formatada.

Conclusões e Implicações Críticas de Implantação

O advento tecnológico dos modelos Jev e o estabelecimento formal da ontologia "System One" solidificam a fragmentação natural na evolução das interfaces intelectuais cognitivas para máquinas. A transição da dependência sistêmica total do paradigma de LLMs generalistas, autorregressivos (System 2) lentos, e extremamente caros computacionalmente para micro-sistemas paralelos, rigorosos, baseados na correlação restrita da estatística embutida prova as virtudes matemáticas esquecidas pelas regressões de amostragem.

A otimização algorítmica liderada pelo refinamento pós-treinamento calçado nos objetivos imutáveis da correlação e penalização probabilística genuína (RLCD) expõe os graves défices estruturais na confiança declarativa forjada e sicofante inerente à natureza estocástica ensinada aos LLMs (RLHF). A devolução irrestrita do *Brier Score*, e a transparência contínua quantificada via ECE sob uma lógica isolada por máscaras (block-causal) permite finalmente a introdução legal e autônoma sem supervisão orgânica humana a bilhões de operações processuais diárias em microsserviços e robótica escalar.

Para os arquitetos e gestores de infraestruturas industriais, a premissa incontestável impõe que modelos da taxonomia Jev não substituem e nem possuem mérito lógico equivalente para competir frente às fronteiras densas de reflexão humana das mega-redes da OpenAI ou Anthropic. A implantação otimizada preconiza a simbiose e hierarquização radical do roteamento de processos: Instâncias estritas *System One* devem encabeçar integralmente a vanguarda e retaguarda periférica na proteção do sistema, classificando falhas, acionando agentes, escalonando complexidades e mitigando alucinações das IA. As chamadas iterativas de custo monetário severo baseadas na geração massiva de *System 2* encontram aí refúgio apenas e exclusivamente para responder e preencher os domínios ontológicos, filosóficos e heurísticos em que os eixos determinísticos da lógica computacional revelam impotência insuperável.

Referências citadas

1. TypeSafe AI Emerges From Stealth With \$40M in Funding With New, <https://www.businesswire.com/news/home/20260915525333/en/TypeSafe-AI-Emerges-From-Stealth-With-%2440M-in-Funding-With-New-Model-for-Composable-AI>
2. Criador do ChatGPT lança IA sem texto e capta US\$ 40 milhões, <https://exame.com/inteligencia-artificial/ele-ajudou-a-criar-o-chatgpt-e-agora-construiu-uma-ia-que-se-recusa-a-conversar/>
3. Jev (AI model) - Wikipedia, [https://en.wikipedia.org/wiki/Jev_\(AI_model\)](https://en.wikipedia.org/wiki/Jev_(AI_model))
4. TypeSafe exits stealth with \$40M seed to build AI for software, not, <https://dealroom.co/news/151032-typesafe-exits-stealth-with-40m-seed-to-build-ai-for-software-not-people/>
5. What Is Jev? TypeSafe AI's System One Model Explained - You.com, <https://you.com/resources/what-is-jev>
6. TypeSafe AI's Jev doesn't write, code or chat. So why are developers obsessed with it?, <https://m.economictimes.com/ai/ai-insights/typesafe-ais-jev-doesnt-write-code-or-chat-so-why-are-developers-obsessed-with-it/articleshow/134436375.cms>
7. Jev: A New AI Model That Refuses to Write Text Has Developers, <https://www.trendingtopics.eu/jev-a-new-ai-model-that-refuses-to-write-text-has-developers-hooked/>
8. Jev Explained: The AI Model Built to Decide, Not Talk - Gnana Prasath, <https://gnana70.medium.com/jev-explained-the-ai-model-built-to-decide-not-talk-ff9604b93ab8>
9. Jev by TypeSafe AI: Is the 200x Faster Decision Model Too Good to, <https://flowtivity.ai/blog/jev-typesafe-ai-decision-model/>
10. What Is Jev? TypeSafe AI's System One Model | Zapier, <https://zapier.com/blog/jev/>
11. A deep dive into Jev, TypeSafe's System One model - Flavio Copes, <https://flaviocopes.com/jev/>
12. Jev: System One Decision Engine Delivering 193.6x Faster Execution, <https://medium.com/aimonks/jev-system-one-decision-engine-delivering-193-6x-faster-execution-b6ac214d93a1>
13. What is Jev, an AI 'generalist' model with a new take on decision-making?, <https://indianexpress.com/article/technology/artificial-intelligence/meet-jev-new-ai-model-from-chatgpt-inventor-10887591/>
14. Jev and System One models: typed decisions - noze, <https://www.noze.it/en/insights/jev-system-one-typed-decisions/>
15. What is RLCD in Jev AI?. What is Reinforcement Learning for, <https://medium.com/data-science-in-your-pocket/what-is-rlcd-in-jev-ai-8f4ba1ac1b47>
16. TypeSafe (Jev) | Pydantic Docs, <https://pydantic.dev/docs/ai/models/typesafe/>
17. Your AI agent is burning tokens on choices that don't need words, <https://thenewstack.io/kev-skips-text-generation/>
18. Kev-0.5B: A Tiny Open Source Jev-like Decision Model | Zeniteq, <https://www.zeniteq.com/kev-0-5b-a-tiny-open-source-jev-like-decision-model->

[nly75](#)

19. README.md · jaredpalmer/kev-0.5b at main - Hugging Face,
<https://huggingface.co/jaredpalmer/kev-0.5b/blame/main/README.md>
20. onnx-community/kev-0.6b-ONNX - Hugging Face,
<https://huggingface.co/onnx-community/kev-0.6b-ONNX>
21. Jev: A New Kind of AI Model Built for Decisions, Not Conversation,
<https://www.edenai.co/post/jev-a-new-kind-of-ai-model-built-for-decisions-not-conversation>
22. Jev and TypeSafe AI: Inside the First System One Model and RLCD,
<https://analyticsmadesimple.com/tutorials/jev-typesafe-ai-system-one-model-rlcd-tutorial/>
23. Jev and system one models: benchmarks, open-source alternatives,
<https://regolo.ai/jev-and-system-one-models-benchmarks-open-source-alternatives-and-when-to-use-them/>
24. Jev and System One Models: Fast Decisions Instead of Generated,
<https://nishbhana.com/Jev-System-One-Models/>
25. Looking under the hood of "System One" models (Jev) - Reddit,
https://www.reddit.com/r/regolo_ai/comments/1wo072l/looking_under_the_hood_of_system_one_models_jev/
26. How to Use Jev in Python: Choice, Noul, Score + OpenAI Comparison,
<https://mljar.com/blog/jev-python/>
27. How to Use Jev: A practical guide to TypeSafe's System One model,
<https://dev.to/valyuai/how-to-use-jev-a-practical-guide-to-typesafes-system-one-model-g5e>
28. <https://dev.to/aws-builders/jev-after-eight-days-of-independent-tests-level-with-mid-price-llms-behind-the-frontier-1c60>
29. What is RLCD (Reinforcement Learning for Calibrated Decisions)?,
<https://www.sanity.io/glossary/rlcd-reinforcement-learning-for-calibrated-decisions>
30. RLCD vs RLHF: What Is Typesafe's Jev Model Actually Claiming?,
<https://www.mindstudio.ai/blog/typesafe-jev-rlcd-vs-rlhf>
31. Evaluating Decision Models for Text Annotation in Computational,
<https://arxiv.org/abs/2609.24574>
32. Calibrated Probabilities: Confidence You Can Act On - Laya Studio,
<https://laya.studio/learn/calibrated-probabilities>
33. Calibrated One-Pass Scam Screening with a Small Language Model,
<https://arxiv.org/pdf/2609.23959>
34. Enhancing Medical Predictions: A Comprehensive Guide to Model,
<https://medium.com/@cartelgouabou/enhancing-medical-predictions-a-comprehensive-guide-to-model-calibration-3ea741be88d7>
35. Fine-Tuning Jev: You Can't. Here's What Gets You the Same Effect,
<https://anth.us/blog/fine-tuning-jev/>
36. jaredpalmer/kev-0.5b - Hugging Face,
<https://huggingface.co/jaredpalmer/kev-0.5b>
37. I Watched a Playtester Talk an AI Merchant Out of a Quest Key With,

- https://medium.com/@ashutosh_veriprajna/i-watched-a-playtester-talk-an-ai-merchant-out-of-a-quest-key-with-one-sentence-3b58e39bd1ef
38. The Ultimate Guide to Jev: The new Frontier AI for faster decisions,
<https://medium.com/@unicodeveloper/the-ultimate-guide-to-jev-the-new-frontier-ai-for-faster-decisions-acd78e5f4c56>
 39. Calibrated Decisions at Scale: Converting Police Crash Narratives,
<https://arxiv.org/abs/2609.24052>
 40. classify_large_quantities_of_text.md · John6666/forum1 at main,
https://huggingface.co/datasets/John6666/forum1/blob/main/classify_large_quantities_of_text.md
 41. Research → practice — AI Research & Projects | AI Experts Directory,
<https://aiexpertsdirectory.org/missions/research-to-production>
 42. Top 7 Open-Source TypeSafe Jev Alternatives - DataCamp,
<https://www.datacamp.com/blog/top-open-source-jev-alternatives>
 43. jaredpalmer/kev-0.8b - Hugging Face,
<https://huggingface.co/jaredpalmer/kev-0.8b>
 44. Kev cuts AI agent token waste by skipping text generation... - Marsel,
<https://marsel.app/news/65887330-f73d-43b7-9c2f-71429ecc977e>
 45. Calibrated One-Pass Scam Screening with a Small Language Model,
<https://arxiv.org/abs/2609.23959>
 46. Calibrated One-Pass Scam Screening with a Small Language Model,
<https://arxiv.org/html/2609.23959v1>
 47. Jev By TypeSafe : A model you were waiting for! - Medium,
<https://medium.com/@visrow/jev-by-typesafe-a-model-you-were-waiting-for-19e8fa8cb5cb>
 48. Retrieval Augmented Decision-Making: A Requirements-Driven,
https://www.researchgate.net/publication/392105553_Retrieval_Augmented_Decision-Making_A_Requirements-Driven_Multi-Criteria_Framework_for_Structured_Decision_Support
 49. Retrieval-Augmented Decision Engines vs RAG: Arch & Use Cases,
<https://leanware.co/insights/retrieval-augmented-decision-engines-vs-rag>
 50. [2505.18483] Retrieval Augmented Decision-Making - arXiv,
<https://arxiv.org/abs/2505.18483>
 51. RAD: Retrieval-Augmented Decision-Making of Meta-Actions ... - arXiv,
<https://arxiv.org/abs/2503.13861>
 52. RAD: Retrieval-Augmented Decision-Making of Meta-Actions with,
https://openaccess.thecvf.com/content/CVPR2025W/WDFM-AD/papers/Wang_RAD_Retrieval-Augmented_Decision-Making_of_Meta-Actions_with_Vision-Language_Models_in_Autonomous_CVPRW_2025_paper.pdf
 53. An Explainable and Fair AI Tool for PCOS Risk Assessment - arXiv,
<https://arxiv.org/pdf/2511.11636>